

MACKENZIE - BANCO DE DADOS - 2026.1

PROJETO APLICADO I

COMPONENTE CURRICULAR:		Banco de Dados - Projeto Aplicado I	
GRUPO 01			
NOME COMPLETO	Caio Balista Ferreira Pedretti	RA: 10751989	
DOS ALUNOS:	Kauan Lima da Silva	RA: 10748047	
	Leonardo de Barros Magalhães	RA: 10752304	

A4 - Aplicando Conhecimento - 07/06/2026

Nome da empresa: Spotify

Link para Github:

<https://github.com/CaioPedretti/Projeto-Aplicado-I-Grupo-1>

Link para apresentação no YouTube:

<https://www.youtube.com/watch?v=EgcDTeqSNYw>



Lista de Imagens

Imagem 1 - Distribuição de Horas Ouvidas por Semana.....	19
Imagem 2 - Dispersão de Idade por Plano.....	19
Imagem 3 - Frequência de Notas das Sugestões.....	20
Imagem 4 - Relação: Horas Ouvidas vs Pulos (Skips).....	20

Lista de Tabelas

Tabela 1 - Métricas extraídas da análise exploratória.....	18
--	----



Sumário

Lista de Imagens.....	1
Lista de Tabelas.....	1
Sumário.....	2
Glossário.....	3
Contexto de estudo e objetivos do trabalho.....	4
Cronograma.....	5
Apresentação da empresa: Spotify.....	6
Apresentação dos metadados.....	8
Conclusão sobre os metadados.....	11
Proposta Analítica e Abordagem Estatística.....	12
Análise Exploratória.....	13
Código.....	13
Output.....	18
Esboço do Storytelling.....	22
1. Introdução e Contextualização (Duração estimada: 1min 30s).....	22
2. A Área do Problema e o Gap Identificado (Duração estimada: 1min 30s).....	22
3. Análise Exploratória e Abordagem Estatística (Duração estimada: 2min).....	23
4. Resultados Pretendidos e Insights das Visualizações (Duração estimada: 2min).....	23
5. Conclusão do Roteiro (Duração estimada: 3min).....	23

Glossário

Chave Primária (Primary Key): Em banco de dados, é um identificador único e exclusivo para cada registro dentro de uma tabela. No contexto do trabalho, é representada pela coluna `user_id`, garantindo que nenhum usuário seja confundido com outro.

CSV (Comma-Separated Values): Formato de arquivo simples que armazena dados tabulares em texto puro, onde cada valor é separado por uma vírgula. É o formato utilizado no dataset do projeto.

Dataset: Um conjunto de dados estruturados. No trabalho, refere-se ao arquivo extraído da plataforma Kaggle contendo as 50.000 linhas de informações simuladas sobre o comportamento dos usuários.

Float: Tipo de dado utilizado em bancos de dados e programação para representar números reais, ou seja, valores que contêm casas decimais (ex: a coluna `avg_listening_hours_per_week`).

Integer (Inteiro): Tipo de dado numérico que representa números inteiros, sem casas decimais (ex: `age`, `playlists_created`, `avg_skips_per_day`).

Jams: Funcionalidade do Spotify que permite aos usuários criarem sessões de música compartilhadas para audição e interação em tempo real com amigos.

Kaggle: Plataforma online focada em ciência de dados e machine learning, que hospeda competições e disponibiliza grandes conjuntos de dados (datasets) públicos para estudo e análise.

Metadados: "Dados sobre os dados". São as informações que descrevem a estrutura e o conteúdo do dataset, como o tipo de dado de cada coluna, o que ela significa, seus valores máximos/mínimos e sua codificação.

ODS (Objetivos de Desenvolvimento Sustentável): Conjunto de metas globais estabelecidas pela ONU. O documento cita o compromisso do Spotify com o ODS 8 (Trabalho Decente), ODS 10 (Redução das Desigualdades) e ODS 13 (Ação Climática).

Programa EQUAL: Iniciativa do Spotify focada em promover a equidade de gênero, dando destaque e projeção global para mulheres criadoras de conteúdo na plataforma.

Streaming: Tecnologia de transmissão contínua de dados via internet que permite ao usuário consumir áudio e vídeo em tempo real, sem a necessidade de baixar o arquivo inteiro para o dispositivo.

UTF-8: Padrão de codificação de caracteres utilizado mundialmente que garante que textos, acentos e símbolos de diversos idiomas sejam interpretados e exibidos corretamente pelo computador.

Varchar (Variable Character): Tipo de dado usado em bancos de dados para armazenar cadeias de texto (strings) com comprimento variável. Utilizado para colunas de texto descritivo no dataset, como `country`, `subscription_type` e `favorite_genre`.

Contexto de estudo e objetivos do trabalho

Este trabalho tem como foco a análise de dados da empresa Spotify, considerando sua relevância no mercado de streaming e o grande volume de informações geradas pela plataforma. O estudo será realizado a partir de um dataset disponibilizado na plataforma Kaggle, composto por dados simulados, mas baseados em comportamentos reais de usuários dentro do serviço. A proposta é trabalhar com esses dados para identificar padrões de uso, preferências dos usuários e formas de consumo de conteúdo.

Como premissa inicial, o projeto assume que os dados refletem as escolhas reais das pessoas, como o que elas ouvem e quanto tempo passam no app. A ideia é que, ao olhar para esses números, conseguimos entender as estratégias que o Spotify usa para manter os usuários conectados. O trabalho parte do princípio de que analisar esses dados é a melhor forma de entender o sucesso da empresa hoje em dia.



O objetivo principal é transformar esse monte de informação em resultados fáceis de entender. Além da análise dos dados, o trabalho também envolve a organização das informações, a realização de análises exploratórias e a construção de resultados que possam ser interpretados de forma clara. Queremos descobrir, por exemplo, quais tipos de músicas ou podcasts são mais populares e como a plataforma sugere novos conteúdos para cada perfil de pessoa.

Também faz parte do trabalho compreender melhor a empresa e seu papel no mercado, observando seu modelo de negócio, sua atuação global e sua influência na forma como as pessoas consomem música e outros conteúdos digitais. Para isso, o estudo usa o pensamento computacional para bater metas específicas. Isso significa dividir o problema em partes menores, como separar os dados por idade ou região, para encontrar padrões que ajudem a explicar o comportamento do público.

No fim, a meta é usar essa lógica de organização e análise para mostrar como o Spotify usa a tecnologia para ditar tendências. Ao filtrar o que é mais importante nos dados, o projeto consegue mostrar de um jeito simples como a empresa funciona por dentro e como ela consegue ser líder no setor de streaming no mundo todo.

Cronograma

O cronograma foi feito no google sheets e com o objetivo de designar o que deve ser feito e por quem, denotando os atributos e as datas de cada entrega.



Apresentação da empresa: Spotify

O Spotify consolidou-se como a maior plataforma de streaming de áudio global, operando um ecossistema que abrange músicas, podcasts e audiolivros. A plataforma gerencia um volume enorme de conteúdo em quase 200 países, mantendo um modelo onde existem tanto usuários que não pagam (mas ouvem anúncios) quanto assinantes premium. Um dos grandes diferenciais que sustenta esse modelo é o uso avançado de inteligência artificial. O Spotify não funciona apenas como uma biblioteca, mas como um curador pessoal que aprende os gostos de cada um. Essa capacidade de processar dados para sugerir a música certa no momento certo é o que garante que os usuários continuem usando o aplicativo diariamente.

A missão do Spotify é liberar o potencial da criatividade humana, dando a artistas a oportunidade de viver de sua arte e aos fãs a chance de se inspirarem. Sua visão é ser uma plataforma cultural que une criadores e consumidores, promovendo empatia e conexão. Os valores fundamentais da empresa incluem colaboração, inovação, sinceridade, paixão e diversão. Analisando-se os últimos anos do Spotify, é possível identificar os seguintes objetivos do desenvolvimento sustentável (ODS):

ODS 8: Trabalho Decente e Crescimento Econômico

- **Foco:** Sustento da economia criativa.
- **Ação:** Pagamento de bilhões em royalties todos os anos, permitindo que músicos e podcasters monetizem seus conteúdos.

ODS 10: Redução das Desigualdades

- **Foco:** Democratização e diversidade no áudio.
- **Ação:** Uso do algoritmo e curadoria (como o programa *EQUAL*) para dar projeção global a artistas independentes, mulheres e minorias.

ODS 13: Ação Contra a Mudança Global do Clima

- **Foco:** Redução da pegada de carbono da tecnologia.
- **Ação:** Compromisso de zerar emissões até 2030, otimizando a eficiência dos servidores na nuvem e o gasto de energia com processamento de dados.

Toda essa estrutura tecnológica e de mercado se reflete diretamente no desempenho da plataforma. Hoje, os dados operacionais comprovam o domínio absoluto do Spotify no setor de áudio digital:

Conteúdo:

- **Músicas:** +100 milhões de faixas.
- **Podcasts:** 7 milhões de títulos.
- **Audiolivros:** 500 mil títulos.

Segmentação de Usuários:

- **Total de Usuários:** 751 milhões.
- **Assinantes (Premium):** 290 milhões.
- **Usuários Free (implícito):** 461 milhões.



Alcance Geográfico:

- **Mercados Ativos:** 184 países/regiões.

Faturamento:

- **Em 2025:** US\$ 19,44 bilhões, crescimento de cerca de **14,6%** em relação a 2024.

Atualmente, a empresa lidera o setor de streaming no mundo, detendo quase um terço de todos os usuários dessa categoria. Esse sucesso acontece porque ela deixou de ser apenas um lugar para ouvir música e passou a investir pesado em outros formatos, como os podcasts e os audiolivros, que ajudam a manter as pessoas conectadas por muito mais tempo dentro do aplicativo.

Recentemente, a empresa também tem voltado seu interesse para o lado das redes sociais. Isso fica claro com as novas funções que permitem que amigos interajam em tempo real, vejam o que o outro está ouvindo e até criem sessões de música compartilhadas, as chamadas "Jams". Essas atualizações mostram que o Spotify quer que a experiência de ouvir algo seja coletiva, diminuindo a necessidade de o usuário sair do app para conversar sobre música em outras redes.

Outro ponto relevante é a integração cada vez maior com plataformas como Instagram e TikTok. Hoje, é muito fácil compartilhar o que se está ouvindo nos "Stories" ou usar uma música do Spotify em um vídeo curto. Esse movimento estratégico ajuda a empresa a atrair o público mais jovem e a transformar os dados de consumo em conteúdo visual, o que reforça ainda mais a presença da marca no dia a dia digital das pessoas.

Ao analisar esses dados de mercado e as novas funções sociais, o trabalho consegue mostrar como o Spotify se adapta às mudanças de comportamento. A ideia é entender como essas ferramentas ajudam a empresa a crescer e a influenciar não apenas o que as pessoas ouvem, mas também como elas se relacionam e compartilham cultura na internet.



Apresentação dos metadados

Origem (Kaggle): < <https://www.kaggle.com/datasets/sahilislam007/spotify-user-behavior-and-pattern>>

Tipo dos dados: Sintéticos, mas são uma simulação realística

Área: Streaming de música / Comportamento do Usuário

Formato do arquivo: CSV

Codificação: UTF-8

Separador: , (vírgula)

Tamanho do arquivo: 5.61 MB

Licença: MIT

Período de coleta: 31 de Dezembro de 2017 a 28 de Fevereiro de 2026

Total de linhas: 50.000

Total de colunas: 18

user_id (chave primária) [integer]

Identificador exclusivo atribuído a cada usuário no conjunto de dados. Varia de 1 a 50000.

country (país) [varchar]

País onde o usuário está localizado.

Contagem única: 12

Mais comum: India 9%

age (idade) [integer]

Idade do usuário. Varia de 16 a 60.

Média: 38

Desvio Padrão: 13

signup_date (data_de_adexao) [data no formato yyyy-mm-dd]

A data em que o usuário se cadastrou na plataforma.

Varia de 2017-12-31 a 2026-02-28



subscription_type (tipo_de_assinatura) [varchar]

Tipo de assinatura utilizada pelo usuário. Exemplos de dados: Gratuita (Free), Premium, Família (Family), Estudante (Student).

Mais comum: Free 45%

subscription_status (status_da_assinatura) [varchar]

Indica se o usuário possui atualmente uma assinatura ativa (Active) ou inativa (Inactive).

months_inactive (meses_inativos) [integer]

Número de meses que o usuário está inativo na plataforma. Varia de 0 a 18.

inactive_3_months_flag (indicador_inativo_3_meses) [integer]

Indicador binário que mostra se o usuário está inativo há 3 meses ou mais.

1 = Inativo por 3 meses ou mais

0 = Ativo ou inativo recentemente

ad_interaction (interacao_com_anuncio) [varchar]

Indica se o usuário interagiu com anúncios na plataforma. Varia entre Sim (Yes) ou Não (No).

ad_conversion_to_subscription (conversao_de_anuncio_para_assinatura) [varchar]

Indica se um anúncio resultou na conversão do usuário para uma assinatura paga. Varia entre Sim (Yes) ou Não (No).

music_suggestion_rating_1_to_5 (avaliacao_sugestao_musical_1_a_5) [integer]

Avaliação do usuário (escala de 1 a 5) para o sistema de recomendação de música da plataforma.

1 = Recomendações muito ruins

5 = Recomendações excelentes



avg_listening_hours_per_week (media_horas_ouvidass_por_semana) [float]

Número médio de horas que o usuário passa ouvindo música por semana. Varia entre 0 e 26.3.

favorite_genre (genero_favorito) [varchar]

O gênero musical ouvido com mais frequência pelo usuário. Exemplos: Pop, Rock, Hip-Hop, Eletrônica, Jazz, Clássica.

most_liked_feature (recurso_mais_querido) [varchar]

O recurso que o usuário mais gosta na plataforma. Exemplos: Playlists personalizadas, Descobertas da semana (Discover Weekly), Downloads offline, Podcasts, Compartilhamento social.

desired_future_feature (recurso_desejado_futuro) [varchar]

Recurso que o usuário gostaria de ver adicionado ou melhorado no futuro.

primary_device (dispositivo_principal) [varchar]

Principal dispositivo usado para acessar a plataforma de música. Exemplos: Celular (Mobile), Desktop, Tablet, Smart Speaker.

playlists_created (playlists_criadas) [integer]

Número de playlists criadas pelo usuário. Varia entre 0 e 23.

avg_skips_per_day (media_de_pulos_por_dia) [integer]

Número médio de músicas que o usuário pula por dia. Valores mais altos podem indicar um baixo engajamento com as sugestões. Varia entre 1 e 25.

Conclusão sobre os metadados

A partir da compreensão estrutural do dataset e da exploração inicial dos metadados, identificamos diversas oportunidades práticas para extrair insights valiosos sobre o funcionamento da plataforma. O detalhamento do comportamento dos usuários nos permite ir além dos números básicos e entender a fundo a relação entre o público e o aplicativo.

Filtrando as possibilidades que mais se alinham aos objetivos de negócio do Spotify e à nossa proposta de estudo, selecionamos três frentes principais de análise que consideramos as mais estratégicas para o desenvolvimento deste projeto:

1. Previsão de Churn (Cancelamento ou Abandono de Plataforma)

No mercado de streaming, reter um usuário é tão importante quanto conquistar um novo. O churn representa a taxa de perda de clientes (seja cancelando uma assinatura Premium ou simplesmente parando de abrir o aplicativo). Nossa ideia é cruzar variáveis como o número de meses inativos (`months_inactive`), o indicador de inatividade longa (`inactive_3_months_flag`) e a média de músicas puladas por dia (`avg_skips_per_day`) para identificar padrões que precedem o abandono.

Pergunta analítica central: É possível prever o churn de um usuário com base em seus padrões de inatividade e baixo engajamento?

2. Eficiência do Sistema de Recomendações (Experimentos e Preferências)

Como mencionado anteriormente, o grande diferencial do Spotify é o uso de inteligência artificial para curadoria. Queremos analisar se esse sistema está realmente agradando os usuários do nosso dataset. Para isso, vamos investigar as notas dadas às sugestões musicais (`music_suggestion_rating_1_to_5`), cruzar esses dados com os gêneros favoritos (`favorite_genre`) e observar o volume de playlists criadas (`playlists_created`).

Pergunta analítica central: Usuários com maior número de playlists criadas são ouvintes mais ativos? A alta taxa de "pulos" de música reflete uma insatisfação com o algoritmo de recomendação?

3. Análise de Marketing e Conversão de Assinaturas

O modelo de negócios do Spotify depende fortemente da conversão de usuários do plano Gratuito (que ouvem anúncios) para os planos pagos (Premium, Família, Estudante). Analisaremos o comportamento de marketing do aplicativo focando nas interações com propaganda (`ad_interaction`) e verificando se essas campanhas realmente resultam em novas assinaturas (`ad_conversion_to_subscription`).

Pergunta analítica central: Quais fatores influenciam a melhoria (upgrade) da assinatura? A interação com os anúncios tem uma correlação direta e positiva com a conversão para planos pagos?

Em suma, a escolha deste dataset e a definição destas três linhas de investigação nos fornecem a base ideal para alcançar todos os resultados propostos para a disciplina. Com esses dados em mãos, seremos capazes de percorrer o ciclo analítico completo do projeto: iniciando com a elaboração da proposta analítica estruturada, avançando para uma análise exploratória de dados robusta para identificar padrões de comportamento e, por fim, aplicando o Data Storytelling para traduzir números em insights claros e narrativas estratégicas sobre o modelo de negócios do Spotify.

Proposta Analítica e Abordagem Estatística

Para responder às perguntas centrais definidas na nossa conclusão — como prever o *churn*, avaliar o algoritmo de recomendação e entender a conversão de anúncios —, não basta observar os dados brutos. É necessário aplicar o rigor da estatística descritiva para traduzir as 50.000 linhas do *dataset* em perfis de comportamento claros.

Esta seção detalha o roteiro analítico que será aplicado a todas as variáveis quantitativas do estudo. O objetivo é estabelecer o perfil do usuário "típico" do Spotify e, mais importante, entender as margens de variação que separam um usuário altamente engajado de um usuário prestes a abandonar a plataforma.

Para isso, nossa análise será dividida nas seguintes etapas estatísticas e visuais:

1. Medidas de Posição (Encontrando o Padrão do Usuário) As medidas de tendência central nos ajudarão a definir o comportamento padrão do público alvo na plataforma.

- **Média:** Será calculada para entender o consumo geral, como a média de horas ouvidas por semana (**avg_listening_hours_per_week**) ou a média de músicas puladas (**avg_skips_per_day**).
- **Mediana:** Fundamental para evitar que valores extremos (usuários que ouvem música 24 horas por dia) distorçam a nossa visão do ouvinte comum, dividindo nossa base exatamente ao meio.
- **Moda:** Utilizada para identificar os comportamentos mais frequentes, como a nota mais comum dada ao sistema de sugestões (**music_suggestion_rating_1_to_5**) ou a idade mais recorrente dos usuários (**age**).

2. Separatrizes (Segmentando Níveis de Engajamento) Não podemos tratar todos os usuários como um grupo único. Utilizaremos os **Quartis (Q1, Q2, Q3)** para fatiar o *dataset* em quatro partes iguais.

- O cálculo dos quartis será vital para a nossa análise de *Churn* e Recomendações. Por exemplo, ao calcular os quartis de **playlists_created**, poderemos isolar os 25% de usuários que mais interagem com a plataforma (acima do Q3) e compará-los com os 25% menos engajados (abaixo do Q1).

3. Medidas de Dispersão (Avaliando a Previsibilidade) Saber a média não é suficiente se não soubermos o quanto os usuários desviam desse comportamento central.

- **Medidas Absolutas (Amplitude, Variância e Desvio Padrão):** Aplicaremos essas métricas para mensurar a volatilidade do uso. Um desvio padrão alto na coluna **avg_skips_per_day** pode indicar que o algoritmo do Spotify acerta muito para um grupo, mas erra drasticamente para outro. A amplitude nos mostrará a distância entre o usuário menos ativo e o mais viciado da base.
- **Medidas Relativas (Coeficiente de Variação - CV):** Como nossas colunas possuem grandezas diferentes (idade em anos, escuta em horas, avaliação de 1 a 5), o Coeficiente de Variação será utilizado para comparar a estabilidade dessas variáveis. Isso nos dirá, por exemplo, se a idade dos usuários varia mais do que o tempo que eles passam ouvindo música.

4. Visualização de Dados (Construção de Gráficos) A estatística descritiva será acompanhada de representações visuais (Data Storytelling) para facilitar a interpretação dos resultados e a tomada de decisão:

- **Histogramas:** Para visualizar a distribuição de variáveis contínuas, como as horas ouvidas.
- **Boxplots (Diagramas de Caixa):** Baseados nos nossos quartis, serão essenciais para identificar *outliers* (pontos fora da curva, como usuários que ficaram inativos por um número anormal de meses).
- **Gráficos de Dispersão:** Para cruzar variáveis e visualizar correlações descritas nas nossas três frentes de estudo (ex: cruzar `avg_listening_hours_per_week` com `music_suggestion_rating_1_to_5`).

Através dessa modelagem matemática, o projeto deixará o campo das hipóteses e passará a comprovar, com números e gráficos, as dinâmicas de retenção e conversão que fazem do Spotify o líder do mercado de *streaming*.

Análise Exploratória

Para a execução prática da proposta analítica, desenvolvemos um algoritmo em linguagem **Python**, utilizando o ecossistema de bibliotecas líderes em Ciência de Dados: **Pandas** e **Numpy** para a manipulação matricial e cálculos matemáticos, e **Seaborn** e **Matplotlib** para a construção das camadas visuais.

O intuito deste script é triplo:

1. **Precisão e Escalabilidade:** Automatizar o cálculo de múltiplas métricas para as 50.000 linhas do *dataset*, evitando erros manuais e permitindo a reprodutibilidade da análise.
2. **Padronização:** Normalizar a extração de dados quantitativos para variáveis de naturezas distintas (como idade, tempo e avaliações).
3. **Diagnóstico Visual:** Transformar tabelas abstratas em representações gráficas que permitem identificar imediatamente a concentração de dados, a presença de *outliers* (valores anômalos) e correlações entre comportamentos de consumo.

Código

```
import pandas as pd

import numpy as np

import matplotlib.pyplot as plt

import seaborn as sns

# 1. Carregar o dataset
```

```
df = pd.read_csv('spotify_user_behavior.csv') # Ajuste o nome do
arquivo se necessário

# Selecionando apenas as colunas quantitativas descritas nos seus
metadados

colunas_quant = [

    'age', 'months_inactive', 'music_suggestion_rating_1_to_5',

    'avg_listening_hours_per_week', 'playlists_created',
    'avg_skips_per_day'

]

def calcular_estatisticas(df, colunas):

    resultados = []

    for col in colunas:

        # Medidas de Posição

        media = df[col].mean()

        mediana = df[col].median()

        moda = df[col].mode()[0]

        q1 = df[col].quantile(0.25)
```

```
q3 = df[col].quantile(0.75)

# Medidas de Dispersão

amplitude = df[col].max() - df[col].min()

variancia = df[col].var()

desvio_padrao = df[col].std()

cv = (desvio_padrao / media) * 100 if media != 0 else 0

resultados.append({

    'Coluna': col,

    'Média': round(media, 2),

    'Mediana': mediana,

    'Moda': moda,

    'Q1 (25%)': q1,

    'Q3 (75%)': q3,

    'Amplitude': amplitude,

    'Variância': round(variancia, 2),

    'Desvio Padrão': round(desvio_padrao, 2),

    'CV (%)': round(cv, 2)
```

```
    })

    return pd.DataFrame(resultados)

# Executar cálculos

tabela_estatistica = calcular_estatisticas(df, colunas_quant)

print(tabela_estatistica)

# --- GERAÇÃO DE GRÁFICOS ---

# Configuração visual

sns.set_theme(style="whitegrid")

plt.figure(figsize=(15, 10))

# 1. Histograma de Horas Ouvidas (Distribuição)

plt.subplot(2, 2, 1)

sns.histplot(df['avg_listening_hours_per_week'], kde=True,
color='green')

plt.title('Distribuição de Horas Ouvidas por Semana')
```

```
# 2. Boxplot de Idade por Tipo de Assinatura (Separatrizes e Outliers)

plt.subplot(2, 2, 2)

sns.boxplot(x='subscription_type', y='age', data=df, palette='viridis')

plt.title('Dispersão de Idade por Plano')


# 3. Gráfico de Barras: Avaliação do Algoritmo (Frequência/Moda)

plt.subplot(2, 2, 3)

sns.countplot(x='music_suggestion_rating_1_to_5', data=df,
palette='magma')

plt.title('Frequência de Notas das Sugestões')


# 4. Dispersão: Horas Ouvidas vs Skips por Dia (Correlação)

plt.subplot(2, 2, 4)

sns.scatterplot(x='avg_listening_hours_per_week',
y='avg_skips_per_day', alpha=0.5, data=df)

plt.title('Relação: Horas Ouvidas vs Pulos (Skips)')


plt.tight_layout()

plt.show()
```

Output

Após a execução do algoritmo de processamento de dados, obtivemos uma visão quantitativa consolidada do nosso *dataset*. Os resultados foram divididos em duas entregas complementares: um sumário estatístico tabular, que nos fornece a exatidão matemática das medidas de posição e dispersão, e um painel visual (Data Storytelling), que facilita o reconhecimento imediato de padrões, concentrações e anomalias.

A tabela a seguir sumariza as métricas extraídas, enquanto o painel de quatro gráficos ilustra, respectivamente: a distribuição da carga horária de escuta, a relação demográfica entre idade e tipo de assinatura, o nível de satisfação com a inteligência artificial de recomendação e, por fim, a correlação entre o tempo de uso e a taxa de rejeição de faixas (pulos). Juntas, essas saídas formam a base empírica para a nossa análise comportamental.

	Média	Mediana	Moda	Q1	Q3	Amplitude	Variância	Desvio Padrão	CV (%)
age	38,01	38,00	47,00	27,00	49,00	44,00	168,61	12,98	34,16%
months_inactive	1,53	1,00	0,00	0,00	2,00	18,00	3,81	1,95	127,34 %
music_suggestion_rating_1_to_5	3,64	4,00	4,00	3,00	5,00	4,00	1,24	1,11	30,58%
avg_listening_hours_per_week	9,99	9,98	0,00	7,28	12,68	26,25	15,75	3,97	39,73%
playlists_created	8,00	8,00	7,00	6,00	10,00	23,00	8,02	2,83	35,38%
avg_skips_per_day	10,03	10,00	10,00	8,00	12,00	24,00	10,02	3,17	31,57%

Tabela 1 - Métricas extraídas da análise exploratória




Imagem 1 - Distribuição de Horas Ouvidas por Semana




Imagem 2 - Dispersão de Idade por Plano




Imagem 3 - Frequência de Notas das Sugestões




Imagem 4 - Relação: Horas Ouvidas vs Pulos (Skips)

A análise estatística e visual traça um perfil nítido do usuário médio, gerando quatro **insights** fundamentais:

1. **Usuários Dormentes:** O histograma mostra engajamento centralizado em 10h/semana, mas revela um pico crítico no zero. Identificar esse público "dormente" é a prioridade para estratégias de retenção e combate ao *churn*.
2. **Idade vs. Assinatura:** O *boxplot* prova que a idade não define o plano. A mediana de 38 anos é constante em todos os níveis, sugerindo que a conversão para o Premium depende do hábito de escuta, não da demografia.
3. **Sucesso da IA:** A satisfação com as recomendações é alta, com moda e mediana em 4.0. A baixa frequência de notas 1 e 2 confirma a eficiência do algoritmo na curadoria e retenção.
4. **Hábito do "Skip":** O *scatterplot* não mostra correlação linear entre tempo de uso e pulos. A média de 10 *skips* diários independe das horas ouvidas, indicando que pular faixas é um comportamento de navegação, não necessariamente insatisfação.

Estes achados fundamentam as questões que guiarão a próxima etapa de cruzamento de dados:

- **Churn:** O que separa o usuário ativo do "pico zero"? Quais limites de inatividade ou *skips* sinalizam o abandono iminente?
- **Algoritmo:** Notas baixas de recomendação estão ligadas a taxas de pulos maiores em nichos específicos?
- **Conversão:** Já que a idade é irrelevante, quais métricas de engajamento realmente impulsionam o *upgrade* do plano Free para o Premium?

Esboço do Storytelling

1. Introdução e Contextualização (Duração estimada: 1min 30s)

Olá a todos. Somos o **Grupo 01**, composto por Caio Pedretti, Kauan Lima e Leonardo Magalhães, estudantes de Banco de Dados no Mackenzie. Estamos aqui para apresentar o desenvolvimento do nosso **Projeto Aplicado I**, referente ao primeiro semestre de 2026.

O foco central do nosso estudo é o **Spotify**, a maior plataforma de streaming de áudio do mundo. Hoje, o Spotify gerencia mais de 100 milhões de faixas de música e possui uma base que ultrapassa 750 milhões de usuários globais. Nosso objetivo com este trabalho é ir além da superfície do aplicativo e entender, por meio da Ciência de Dados, as estratégias analíticas que sustentam esse modelo de negócio bilionário.

Para isso, nosso grupo se comprometeu com uma abordagem alinhada aos Objetivos de Desenvolvimento Sustentável da ONU, especificamente o ODS 8, voltado ao trabalho decente e fomento da economia criativa por meio do pagamento de royalties, e o ODS 10, que utiliza a inteligência artificial para reduzir desigualdades e dar palco a artistas independentes e minorias em 184 países.

2. A Área do Problema e o Gap Identificado (Duração estimada: 1min 30s)

Embora o Spotify apresente um faturamento expressivo, fechando 2025 na casa dos 19,4 bilhões de dólares, o mercado de streaming enfrenta um desafio crítico: a retenção e a conversão de usuários. O grande **gap de negócio** que identificamos reside em responder com precisão: *o que faz um usuário migrar da plataforma gratuita para os planos pagos e, inversamente, o que o leva a abandonar o aplicativo (Churn)?*

Para responder a essas perguntas, trabalhamos com um **dataset robusto extraído da plataforma Kaggle**. Trata-se de uma base com 5,61 megabytes de dados estruturados em formato CSV e codificação UTF-8, totalizando **50.000 registros (linhas) e 18 colunas** com metadados detalhados. A chave primária que ancora nossa consistência relacional é o `user_id`. A partir deste ecossistema de dados, estabelecemos a nossa **Proposta Analítica**, dividida em três pilares fundamentais:

1. **Previsão de Churn:** Cruzando inatividade e engajamento.
2. **Eficiência do Algoritmo:** Avaliando a recepção da inteligência artificial através das notas de recomendação.
3. **Conversão de Marketing:** Medindo o impacto real dos anúncios na assinatura de planos Premium.

3. Análise Exploratória e Abordagem Estatística (Duração estimada: 2min)

A fim de obtermos respostas exatas, desenvolvemos um algoritmo em Python utilizando as bibliotecas Pandas, Numpy, Matplotlib e Seaborn. Esse script processou as variáveis quantitativas e nos retornou uma matriz estatística descritiva completa, calculando medidas de posição, separatrizes e dispersão.

Ao analisarmos a nossa **Tabela 1 de Métricas Extraídas**, nos deparamos com dados reveladores sobre o comportamento do ouvinte:

- **Idade:** A média de idade da nossa base é de 38 anos, com um desvio padrão de 12,98 anos. O Coeficiente de Variação de 34,16% mostra uma distribuição demográfica bem distribuída e estável.
- **Uso Semanal:** O usuário médio consome cerca de 10 horas de áudio por semana. Entretanto, a amplitude de 26,25 horas aponta a existência de extremos na base — desde contas completamente paradas até ouvintes intensivos.
- **Avaliação do Sistema:** A moda e a mediana encontram-se fixadas na nota 4,00, indicando uma percepção geral altamente positiva do algoritmo.

4. Resultados Pretendidos e Insights das Visualizações (Duração estimada: 2min)

A tradução dessas métricas em nosso painel visual de Data Storytelling confirmou nossas hipóteses e desenhou os **resultados pretendidos** para a entrega final do projeto.

A **Imagem 1 (Distribuição de Horas Ouvidas)** confirmou o engajamento médio de 10 horas semanais, mas expôs visualmente um pico alarmante de usuários posicionados no marco zero. Esse é o público dormente que pretendemos mapear para mitigar o Churn.

A **Imagem 2 (Dispersão de Idade por Plano)** trouxe uma quebra de paradigma: a mediana de idade permanece rigorosamente a mesma em todos os planos (Free, Premium, Family, Student). Isso prova matematicamente que a idade não determina o tipo de assinatura; a conversão é puramente comportamental.

A **Imagem 3 (Frequência de Notas)** validou a eficiência da Inteligência Artificial do Spotify. O volume massivo de notas 4 e 5 mostra o sucesso da retenção algorítmica. Por fim, a **Imagem 4 (Relação Horas vs. Pulos)** não indicou correlação linear. Usuários pulam em média 10 faixas por dia independentemente do tempo que passam logados, provando que o "skip" é um comportamento natural de navegação do usuário moderno, e não um sintoma isolado de insatisfação.

5. Conclusão do Roteiro (Duração estimada: 3min)

Resumindo, os dados mostram que o sucesso de conversão e retenção do Spotify não depende de quem é o usuário (sua idade ou país), mas sim de *como ele interage* com as ferramentas.

Deslocar o foco de quem é o usuário para como ele interage significa entender que a demografia tradicional falhou no mercado de streaming. Os dados provam que variáveis como idade e país não explicam o consumo ou a conversão de planos no Spotify.

- **Irrelevância Demográfica:** A mediana de idade fixa em 38 anos em todos os planos (Free, Premium, Família e Estudante) comprova que o apelo geracional ou o poder aquisitivo presumido não ditam o upgrade. Da mesma forma, a conversão de anúncios para assinaturas pagas não se correlaciona com o país de origem, mas sim com o nível de engajamento do usuário.
- **A IA como Retentora:** A avaliação positiva das sugestões (moda e mediana 4,00) mostra que a Inteligência Artificial é calibrada pelo comportamento. Quanto mais o usuário interage, mais o algoritmo aprende, criando uma curadoria personalizada que impede o abandono da plataforma (*churn*).
- **Patrimônio Digital:** O volume de playlists criadas funciona como uma barreira de saída. O usuário acumula um histórico de personalização dentro do app que ele não deseja perder migrando para um concorrente.
- **Mecânica de Navegação:** A média constante de 10 pulos por dia, independentemente das horas ouvidas por semana, revela que o "skip" é apenas um hábito natural de controle e exploração do fluxo de áudio, e não um indicador de insatisfação.

O Spotify opera, portanto, como um ecossistema autoalimentado: o comportamento do usuário calibra o produto, e a personalização retém o usuário. Os dados de interação são as únicas métricas preditivas para o sucesso do modelo de negócios.